

Bloque 8: Razonamiento Bajo Incertidumbre

¿Cómo decide un agente racional cuando no tiene certeza?

- Si el agente tuviera toda la información del ambiente podría razonar con total certeza, pero esto no pasa así que tiene que asignar probabilidad a los hechos y trabajar con eso.

Incetidumbre del mundo real:

- La información es **incompleta**: el agente no observa todo el estado del mundo
- Hay **ruido**: los sensores se equivocan, los datos tienen errores
- Las acciones tienen **efectos impredecibles**: hacer A no siempre lleva al estado esperado

Probabilidad como grado de creencia

- La visión frecuentista dice: probabilidad = fracción de veces que ocurre algo en repeticiones
- La visión **bayesiana** dice: probabilidad = grado de creencia racional dado lo que sé ahora
- Ejemplo: $P(\text{llueve mañana}) = 0.7$ no significa que llovió el 70% de los días pasados, significa que con la información que tengo hoy, creo que hay 70% de chance de que llueva
- Esta visión permite razonar sobre eventos únicos e irrepetibles

Variables aleatorias, probabilidad conjunta y condicional

Variable aleatoria: una variable que puede tomar distintos valores con ciertas probabilidades. Ejemplo: `Spam ∈ {true, false}`

Probabilidad conjunta: la probabilidad de que dos cosas ocurran al mismo tiempo

$P(\text{Spam}=\text{true}, \text{Palabra}=\text{"oferta"}) = 0.04$

Falacia de tasa base

Es el error de ignorar la probabilidad prior y quedarse solo con la verosimilitud.

Ejemplo médico clásico y visto en clase: una enfermedad afecta al 1% de la población. Un test tiene 99% de precisión. Si el test da positivo, ¿cuál es la probabilidad de tener la enfermedad?

La intuición dice "99%". Bayes dice algo muy diferente:

$$P(\text{enfermedad} \mid \text{positivo}) = (0.99 \times 0.01) / [(0.99 \times 0.01) + (0.01 \times 0.99)]$$
$$\approx 50\%$$

El resultado es ~50%, no 99%. La tasa base (1% de prevalencia) importa muchísimo.

6. Utilidad esperada

Para tomar decisiones bajo incertidumbre se combina probabilidad con valor:

$$\text{Utilidad esperada} = \sum P(\text{resultado}_i) \times \text{Utilidad}(\text{resultado}_i)$$

Un agente racional elige la acción que **maximiza la utilidad esperada**, no la que tiene el resultado más probable ni la que tiene el mejor resultado posible.

Ejemplo: entre operar (riesgo 10%, ganancia alta) vs no operar (seguro, ganancia baja), el agente calcula cuál tiene mayor utilidad esperada y elige esa.

7. Naive Bayes y redes bayesianas

Naive Bayes: aplica Bayes asumiendo que todas las evidencias son independientes entre sí dado el estado. Es "naive" (ingenuo) porque esa independencia rara vez es real, pero en la práctica funciona sorprendentemente bien.

$$P(\text{Spam} \mid \text{palabra1}, \text{palabra2}, \dots) \propto P(\text{Spam}) \times P(\text{palabra1} \mid \text{Spam}) \times P(\text{palabra2} \mid \text{Spam}) \times \dots$$

Redes bayesianas: grafos donde los nodos son variables y las aristas representan dependencias causales. Permiten razonar con independencias condicionales más realistas. Son el puente hacia modelos probabilísticos más complejos y hacia el aprendizaje automático probabilístico.

Conclusion

la idea de que la probabilidad no es solo estadística de frecuencias sino una forma de representar conocimiento parcial y actualizarlo con evidencia. El teorema de Bayes es simple en su fórmula: cada observación nueva debería cambiar, y cuánto depende de qué tan probable era esa observación en cada escenario. Naive Bayes aplicado al spam muestra eso: el modelo no sabe qué es un spam, solo qué palabras aparecen más en cada clase, y con eso se puede generar una clasificación, que tiene sus errores, pero es útil.