

Informe

Regresión vs. Clasificación

La diferencia es la salida. En regresión predécís un número continuo, en clasificación predécís una categoría discreta. El proceso es similar pero las métricas y los modelos cambian.

Árboles de decisión

Aprenden haciendo preguntas sobre las features y dividiendo los datos en grupos cada vez más puros. La primera pregunta del árbol del Titanic fue el sexo, luego la clase del pasajero — exactamente lo que haría un humano. Son interpretables, podés seguir la lógica pregunta por pregunta. El problema es que tienen alta varianza: cambiar pocos datos de entrenamiento puede cambiar completamente la estructura del árbol, y sin límite de profundidad memorizan el entrenamiento completamente.

Entropía e Information Gain

Para elegir qué pregunta hacer en cada nodo, el árbol mide cuál reduce más la mezcla de clases en los grupos resultantes. La entropía mide qué tan mezclados están los datos — cero si todos son de la misma clase, máxima si están mitad y mitad. El Information Gain es cuánto baja la entropía después de hacer una pregunta. El árbol siempre elige la pregunta con mayor Information Gain.

Ensamblados: Bagging y Boosting

La solución al problema de alta varianza de un árbol solo es combinar muchos árboles.

Bagging entrena N árboles sobre muestras aleatorias del dataset y promedia sus predicciones. Los errores de cada árbol son distintos y al promediar se cancelan. **Random Forest** es bagging donde además cada árbol solo ve un subconjunto aleatorio de features en cada split, lo que hace los árboles menos correlacionados entre sí y reduce más la varianza.

Boosting entrena los árboles de forma secuencial: cada árbol nuevo se enfoca en corregir los errores del anterior. La predicción final es la suma ponderada de todos. **XGBoost** es boosting con regularización y optimización muy eficiente — es el modelo que más competencias de ML gana en la práctica.

Evaluación

En clasificación el error no se mide con MSE. Las métricas dependen del problema:

- **Accuracy:** porcentaje de aciertos. Engañosa con clases desbalanceadas.
- **Precision:** de los que predije como positivos, cuántos realmente lo eran. Importa cuando el falso positivo es caro — en spam no querés bloquear mails legítimos.
- **Recall:** de todos los positivos reales, cuántos detecté. Importa cuando el falso negativo es caro — en enfermedades no querés dejar pasar casos reales.
- **F1:** balance entre precision y recall. Útil cuando querés optimizar ambas.
- **AUC:** qué tan bien el modelo separa las clases en general, independientemente del umbral. 1.0 es perfecto, 0.5 es aleatorio.

En el Titanic, Random Forest ganó en F1 y AUC. El árbol solo tuvo mayor precision pero peor recall — detectó pocos sobrevivientes pero cuando lo hizo acertó más.