

informe

Aprendizaje no supervisado:

En aprendizaje supervisado tenés pares (X, Y) y el modelo aprende a predecir Y . En aprendizaje no supervisado solo tenés X — no hay respuesta correcta. El objetivo es descubrir estructura oculta en los datos: grupos naturales, dimensiones relevantes, anomalías, patrones que nadie etiquetó.

El aprendizaje no supervisado opera sobre conjuntos de datos sin etiquetas explícitas, donde el objetivo no es predecir una variable objetivo sino inferir estructura latente directamente desde la distribución de los datos. El clustering aborda esto agrupando observaciones por similitud: K-Means minimiza la inercia o WCSS asignando iterativamente cada punto al centroide más cercano y recalculando centroides hasta convergencia, mientras que la selección del K óptimo se determina mediante el método del codo o el coeficiente de silueta, que mide la cohesión intra-cluster relativa a la separación inter-cluster. Dado que K-Means asume clusters convexos y es sensible a escala e inicialización, existen alternativas más robustas: DBSCAN define clusters como regiones de alta densidad separadas por zonas dispersas sin requerir K a priori, GMM modela los datos como mezcla de distribuciones gaussianas asignando pertenencias probabilísticas, e Isolation Forest detecta anomalías explotando que los puntos atípicos son estadísticamente más fáciles de aislar mediante particiones aleatorias. Cuando la dimensionalidad del espacio de features es alta, PCA reduce la representación proyectando los datos sobre las componentes de máxima varianza, facilitando visualización, compresión y eliminación de ruido. En sistemas de recomendación, Matrix Factorization descompone la matriz usuario-ítem en factores latentes de baja dimensión que capturan preferencias implícitas no observables directamente. Los embeddings generalizan este principio representando entidades arbitrarias como vectores densos en espacios donde la distancia geométrica codifica similitud semántica o funcional. En conjunto, estos métodos comparten un supuesto estructural común: los datos observados son generados por un proceso latente de menor dimensión, y el objetivo del aprendizaje no supervisado es recuperar ese proceso a partir de las observaciones.