

informe:

El aprendizaje por refuerzo es el paradigma donde un agente aprende a actuar no a partir de datos etiquetados ni de estructura oculta en los datos, sino a partir de la interacción directa con un entorno: ejecuta acciones, recibe recompensas y ajusta su comportamiento para maximizar la recompensa acumulada a largo plazo. El problema central no es predecir ni agrupar sino tomar decisiones secuenciales bajo incertidumbre, donde cada acción afecta el estado futuro y por lo tanto las recompensas futuras. Los Procesos de Decisión de Markov formalizan este escenario con estados, acciones, transiciones y recompensas descontadas por un factor γ que refleja cuánto importa el futuro relativo al presente. La ecuación de Bellman expresa el valor de un estado de forma recursiva: el valor ahora es la recompensa inmediata más el valor descontado del mejor estado al que se puede llegar. Q-Learning traduce eso en un algoritmo concreto: mantiene una tabla $Q(s,a)$ que estima el valor de cada acción en cada estado y la actualiza iterativamente usando la diferencia temporal entre lo que esperaba y lo que obtuvo. El dilema exploración-explotación aparece constantemente: el agente debe explorar acciones nuevas para descubrir mejores estrategias, pero también explotar lo que ya aprendió para maximizar la recompensa actual. ϵ -greedy resuelve esto eligiendo la mejor acción conocida con probabilidad $1-\epsilon$ y una acción aleatoria con probabilidad ϵ . El enfoque tabular funciona bien en entornos pequeños como GridWorld pero escala mal con espacios de estados grandes, lo que motiva la transición hacia Deep RL donde la tabla Q se reemplaza por una red neuronal.